

長庚資工軟硬體專題期末報告書

專題名稱：台灣手語雙向翻譯系統

執行期間：114 年 9 月至 116 年 1 月

指導教授：謝萬雲 教授

計畫參與人員：

B1229017 尹品臻

B1229022 吳珮甄

B1229028 李宜穎

B1229046 周語旋

.

執行單位：長庚大學 資訊工程學系

中華民國 2026 年 4 月 20 日

壹、系統簡介

一、規格目的

本系統旨在將台灣手語 (TSL) 與 AI 技術結合，促進聽障人士及一般人士之間的翻譯交流。透過影像辨識、自然語言處理與手語動畫技術，本系統能夠：

1. 將使用者的 TSL 動作即時轉換為文字或語音。
2. 將文字或語音內容即時轉換為 TSL 動畫。

本系統適用於教育、會議、客服及國際交流場合，致力於提升手語使用者與非手語使用者之間的溝通效率。

二、規格範圍

1. 台灣手語辨識模組 (TSL → 文字/語音)
 - 使用影像辨識技術即時識別手部與臉部動作。
 - 支援常用單詞、短語及日常會話句型的辨識。
 - 使用文本轉換技術轉換手語與中文語系之間的語序差異。
2. 文字/語音轉手語模組
 - 將文字或語音內容轉換為對應 TSL 手語動畫。

三、參考文件

1. 長庚大學設計文件書(參照格式)

貳、系統概述

一、系統目標

本系統旨在突破台灣手語 (TSL) 使用者與非手語使用者之間的資訊交流壁

壘，建構一套具備高準確度、低延遲特性之「雙向手語翻譯與互動系統」。針對

傳統手語翻譯系統常面臨的「動態軌跡難以捕捉」與「手語語法倒裝」兩大技

術瓶頸，本系統提出以下具體目標：

1. 實現高精準度之多模態特徵解析 (Multimodal Feature Extraction)：

捨棄傳統穿戴式感測器，全面採用無涉入式 (Non-intrusive) 電腦視覺

技術。透過 MediaPipe 建立空間座標系，精準捕捉手部 21 節點、人

體姿態與臉部輪廓。系統不僅能辨識靜態手型 (如 V 型、Y 型、握

拳)，更能透過歷史軌跡記憶陣列 (History Buffers)，解析具有時序性

(Temporal) 的複雜動態特徵 (如平移、旋轉、指關節彎曲)，大幅提

升動態手語的辨識成功率。

2. 結合生成式 AI 進行自然語言重組 (NLP & Semantic

Reconstruction)：台灣手語的視覺空間文法 (如時間副詞置首、主賓

動倒裝) 與中文口語存在顯著差異。本系統突破傳統「字對字 (Gloss-

to-Word)」的死板翻譯，導入最新型的大型語言模型 (LLM, 如

Gemini 2.5 Flash)。系統會在使用者打完手語的瞬間，自動將零散的手

語詞彙打包，結合專業的提示詞工程 (Prompt Engineering)，即時進行語法梳理與語意潤飾，輸出符合大眾日常對話邏輯的流暢中文。

3. 建構直覺且無縫的沉浸式互動體驗 (Seamless User Experience)：開發智慧觸發機制 (Smart Triggering)，系統能自主判斷使用者的肢體狀態 (如偵測雙手離開畫面超過 2 秒，即視為單句表達結束)，實現無須按鍵介入的全自動翻譯流程。並將運算結果與 3D 虛擬化身 (Avatar) 技術整合，提供即時視覺化回饋，打造真正無障礙的雙向交流環境。

二、系統範圍

本系統為一套基於網頁之使用者管理與互動系統，主要提供手語使用者與非手語使用者間進行溝通及基本互動功能，以 AI 生成影像提升資訊傳遞與使用者操作之便利性。

1. 系統功能範圍

- 使用者註冊、登入與驗證功能
- 使用者基本資料管理 (新增、修改)
- 系統資料儲存與管理功能
- 基本互動功能 (如語音、文字利用 AI 翻譯成手語)

2. 不包含範圍


- 不支援高即時性通訊
- 不包含第三方登入 (如 Google、Facebook)

- 不提供行動裝置原生應用程式 (僅限 Web)
- 不包含進階資料分析或 AI 推薦功能

三、系統架構

本系統旨在提供跨表達模式 (文字 / 語音 / 手語) 之即時翻譯溝通功能。整體系統架構由前端輸入介面、特徵擷取模組、手語辨識模組、自然語言處理模組、字幕與動畫同步模組、3D 手語動畫生成模組所組成。

1. 系統整體架構圖



2. 各模組功能說明

(1) 使用者介面 (前端)

提供語音、文字、影像輸入，並顯示翻譯後文字與 3D Avatar

手語動畫。使用 Web 技術 (HTML、JavaScript、Three.js)

實作。

(2) MediaPipe 特徵擷取模組

利用 MediaPipe Hands、Face Mesh、Holistic 進行：

- 21 點手部骨架偵測
- 臉部表情與口型偵測
- 全身姿態骨架偵測

輸出統一格式之多模態關鍵點資料 (JSON)。

(3) 手語辨識模組 (TSL)

將 MediaPipe 的骨架資料輸入 AI 模型：

- 使用者比 TSL → 模型輸出中文文字

模型可採用：

- Transformer
- LSTM
- 3D CNN + Temporal Attention

(4) 自然語言處理模組 (NLP)

- POS 標註
- 語法樹建立
- 手語語序 ↔ 口語語序轉換

產生最終的語言輸出文字。

(5) 字幕 / 動畫同步模組

此模組負責讓文字字幕與 3D 手語動畫保持一致時間點播放

三大功能：

- 動畫時間軸解析

讀取每段手語 clip 的開始/結束時間。

- 字幕對應引擎

將文字斷句 (或 gloss 分詞) 與動畫片段配對。

- 同步控制器

3D Avatar 播到哪裡 → 字幕自動切換

字幕換到下一句 → 動畫跳到對應 clip

(6) 3D 手語動畫生成模組 (Blender)

使用 Blender 做：

- 骨架綁定 (Armature Rig)
- 手語動作 Keyframe 自動生成
- Clip 匯出為 glTF/FBX
- 前端 Three.js 讀取播放

此模組可由 AI 自動產 Keyframe，也可 manual 微調。

四、軟/硬體建構項目需求概述

1.軟體

項目編號	軟體項目名稱	功能描述	預計開發工具/庫
------	--------	------	----------

SCI-01	影像特徵擷取 模組	負責啟動鏡頭並透過 MediaPipe 提取 3D 關鍵點座標。	Python, MediaPipe
SCI-02	B 流：幾何邏 輯辨識模組	實作規則判定邏輯， 透過計算手指伸直、 間距與高度等幾何特 徵直接輸出結果。	Python (OpenCV, NumPy)
SCI-03	A 流：AI 語意 翻譯模組	實作深度學習模型， 處理複雜時序動作之 語意辨識。	PyTorch/Transformer /LSTM/GRU
SCI-04	雙向整合控制 中心	負責整合 A/B 流結 果，處理辨識衝突並 派發指令。	Python
SCI-05	3D 動畫驅動 引擎	接收字彙 ID 並調用 Blender 動作庫驅 動虛擬人。	Blender Python API
SCI-06	使用者互動 UI	提供視訊預覽、文字 翻譯顯示及 3D 展 示視窗。	PyQt 或 Web 技術

2.硬體

項目編號	硬體項目名稱	規格需求	用途說明
HCI-01	高畫質影像輸入設備	支援 720p/30fps 以上之 WebCam。	捕捉使用者手語動作。
HCI-02	深度學習運算主機	具備 NVIDIA RTX 系列 GPU 之個人電腦。	執行 AI 模型推論與 3D 渲染。
HCI-03	高解析度顯示器	1920x1080 解析度。	展示翻譯結果與虛擬人動畫。

五、軟/硬體環境

為確保即時影像串流解析與 AI 模型推論之效能，本系統之基礎建構與部署環境規範如下：

1. 硬體環境規格 (Hardware Requirements)

- 邊緣影像感測設備 (HCI-01)：
 - 規格需求：支援 720p (1280x720) / 30 FPS 以上解析度之廣角網路攝影機 (WebCam)。
 - 運作邏輯：為兼顧運算效能與辨識率，系統內部串流處理

會將畫面標準化為 640x480 進行矩陣運算，但高規格輸入設備能確保弱光環境下的特徵點 (Landmarks) 捕捉穩定性。

- 核心運算主機 (HCI-02) :
 - 處理器 (CPU) : 具備多執行緒處理能力之 CPU (如 Intel Core i5/i7 或 AMD Ryzen 5/7 等級以上)，以應付非同步網路請求 (API Requests) 與影像幀讀取。
 - 圖形處理器 (GPU) : 建議配備 NVIDIA RTX 系列獨立顯示卡。用於加速深度學習模型推論、3D 渲染，並分擔 MediaPipe 之電腦視覺節點運算壓力。
- 顯示與輸出設備 (HCI-03) : 1920x1080 (FHD) 以上解析度之顯示器，確保 UI 介面與 3D 手語動畫之呈現細節。

2. 軟體與開發環境 (Software & Development Environment)

- 核心程式語言 : Python 3.9+ (確保多執行緒處理與套件依賴性之最佳相容性)。
- 電腦視覺與感測框架 :
 - OpenCV (cv2) : 負責底層硬體攝影機呼叫、影像串流擷取、色彩空間轉換 (BGR to RGB) 及即時 OSD (On-Screen Display) 資訊疊加。

- MediaPipe (0.9.x+) : 作為骨幹感知引擎，調用 Hands 與 Pose 模組，輸出三維拓樸座標 (X, Y, Z) 供 A/B 雙流模組進行幾何運算。
- 自然語言處理與雲端介接：
 - 使用 requests 套件介接 Google Generative AI API。
 - 系統內建容錯轉移機制 (Failover Routing)，支援自動切換多組備援模型 (如 gemini-2.5-flash, gemini-2.5-flash-lite)，並處理 HTTP 429 (Rate Limit) 或 503(Service Unavailable) 異常，確保翻譯服務高可用性。
- 字型渲染引擎： Pillow (PIL)，用以解決 OpenCV 原生不支援 UTF-8 中文渲染之限制，透過掛載 msjh.ttc (微軟正黑體) 實現高解析度的中文翻譯字幕渲染。

六、一般限制

1. 技術限制

本系統採用 Web 技術進行開發，前端使用 JavaScript 框架 (如 React)，後端採用 Node.js，並以關聯式資料庫 (如 MySQL) 進行資料儲存與管理。

2. 平台限制系統

僅支援於瀏覽器上運行，不支援行動裝置原生應用程式。

3. 開發資源限制

本系統為專題開發，受限於開發時間與人力資源，僅實作核心功能，部分進階功能未納入本次開發範圍。

4. 效能限制

本系統未針對高併發或大規模使用進行優化，主要適用於一般使用情境。

參、設計內容

一、軟/硬體建構項目架構

1.架構層級說明

本架構可細分為以下四個主要層級：

A. 感知輸入層 (Perception Layer)：

- 由 HCI-01 (鏡頭) 獲取原始影像，並透過 SCI-01 (特徵擷取模組) 提取關鍵點。
- 此層級輸出為 3D 座標序列，提供給後續雙流模組使用。

B. 運算處理層 (Processing Layer)：

- B 流 (幾何邏輯流 - SCI-02)：執行即時幾何運算 (如手指

夾角、手掌距離、相對高度)。若判定結果符合預設規則

(如：數字、簡單手勢)，則觸發快速辨識結果。

- A 流 (AI 翻譯流 - SCI-03)：將座標序列輸入至深度學習模型 (Transformer)。此流負責辨識具有動態軌跡與語法邏輯的連續手語。

C. 整合控制層 (Control Layer)：

- 由 SCI-04 (整合中心) 接收 A、B 流之結果。
- 決策邏輯：採權重制或優先制 (例如：B 流判定優先於 A 流)，確保辨識結果之穩定與正確，並排除誤判。

D. 展示呈現層 (Presentation Layer)：

- SCI-05 (動畫引擎)：將最終辨識出的字彙 ID 轉換為 3D 動作指令。
- SCI-06 (互動 UI)：負責在螢幕上呈現翻譯文字結果與 3D 虛擬人動畫

2. 硬體與軟體之互動關係

階段	負責硬體 (HCI)	負責軟體 (SCI)	輸出資料格式
輸入階段	鏡頭 (HCI-01)	影像擷取 (SCI-	640x480 RGB 串

		01)	流
運算階段	GPU 主機 (HCI-02)	A/B 雙流辨識 (SCI-02/03)	座標、機率值、字彙 ID
輸出階段	顯示器 (HCI-03)	3D 動畫與 UI (SCI-05/06)	文字、Blender 骨架動畫

二、軟硬體組件設計說明

1. 影像組件

本組件負責將原始影像轉換為具備不變性 (Invariance) 的特徵向量。透過多層次的正規化處理，消除拍攝距離、人體身材大小及畫面位置帶來的干擾。

1. 技術選型與座標擷取

核心技術：採用 MediaPipe Holistic 擷取全身關鍵點 (Pose, Face, Hands)。

取樣邏輯：為了確保輸入模型 (Transformer/LSTM) 的數據維度恆定，系統執行時間維度正規化：

等間距抽樣：若輸入幀數大於預設長度，採用 `np.linspace` 進行等間距抽樣。

零填充 (Padding)：若輸入幀數不足，則以 `np.zeros` 補足至

30 幀。

2. 空間尺度正規化 (Spatial Normalization)

為解決不同使用者體型與拍攝距離造成的數值差異，系統實施以下空間正規化策略：

以肩寬為基準：定義左肩與右肩之歐幾里得距離為基準長度。

數值轉換：所有臉部、身體及手部移動量均除肩寬。

意義：座標單位從「像素」轉換為「肩膀寬度單位」，實現體型與距離的不變性。

3. 參考原點平移正規化 (Ref-point Normalization)

為消除使用者在畫面中位置（站左、站右）的影響，系統採用局部座標系：

全身與臉部：以鼻子 (Nose, ID 0) 為參考原點，所有座標減去該原點座標，將座標系轉換為以人臉中心為原點。

手部局部化：每一隻手分別以其手腕 (Wrist, ID 0) 為參考原點，計算手指 21 個點相對於手腕的相對位置。

4. 角度特徵正規化 (Angular Normalization)

針對關節彎曲程度，系統不直接使用座標，而是計算夾角並進行映射：

手肘角：將計算出的弧度值除以 π ，將角度範圍從 $[0, \pi]$ 映射

至 $[0, 1]$ 區間。

手指角：擷取手指關節間的弧度特徵，利用弧度天然的界限值提供模型穩定的數值輸入。

意義：加速神經網路收斂，提升對手勢彎曲程度的辨識敏感度。

5. 特徵向量封裝 (Feature Packaging)

最終每一幀影像會被壓縮成一個固定維度 (218 維) 的特徵向量。該向量包含了經過正規化後的 Pose、Face、Left_Hand 與 Right_Hand 特徵，並以 (30, 218) 的張量形式輸出至後續辨識模組。

2. 翻譯組件

本系統的翻譯組件為整體運作之「決策大腦」，採用高容錯率之「混合式雙流架構 (Hybrid Two-Stream Architecture)」，結合深度學習與專家規則系統，分為以下三個核心單元：

1. A 流與 B 流之並行推論層 (Parallel Inference Layer)：

a. A 流 (AI 語意預測流 - SCI-03)：為資料驅動

(Data-Driven) 的深度學習核心。負責接收

MediaPipe 提取之連續 3D 空間座標序列 (歷史軌跡

陣列)，並將其輸入至預先訓練好之 AI 模型 (如

Transformer/LSTM)。此流專精於解析具有高度時序

性、複雜動態軌跡的手語動作，並輸出各候選單字之預測機率 (Confidence Score)。

- b. B 流 (幾何邏輯辨識流 - SCI-02)：為規則驅動 (Rule-Driven) 的專家系統。透過動態載入 database.xlsx 規則庫，即時解析手指張合、三維距離、掌心朝向等絕對幾何特徵。此流專精於靜態手勢與基礎動態的快速、決定性 (Deterministic) 比對，提供極高的局部準確度。

- 2. 整合控制與權重融合核心 (Hybrid Decision Fusion Core - SCI-04)：本模組為系統的「防誤判仲裁機制」，負責匯集 A 流 (AI 機率) 與 B 流 (規則閾值) 的運算結果進行決策層融合 (Decision-Level Fusion)。

- a. 動態權重演算法 (Dynamic Weighting Allocation)：
當雙流產生辨識結果時，系統會套用混合權重計算。例如：對於結構嚴格的靜態手勢，賦予 B 流較高權重以防止 AI 幻覺 (Hallucination)；對於軌跡複雜的連續手語，則採納 A 流的綜合語意預測。
- b. 單字鎖定：綜合加權評分後，系統會選出當下得分最高且最穩定的台灣手語單字 (Gloss)，排除雜訊並將其拋

轉至後端。

3. LLM 語意翻譯核心 (TranslationWorker):

a. 防抖與時序分段：實作 2.0 秒的防抖動機制

(Debounce)，接收融合後的單字存入緩衝陣列。當偵測到「畫面無手部特徵達 2 秒」或「動作停滯超過 5 秒」時，自動觸發翻譯中斷點。

b. 自然語言重組：將打包好的單字陣列發送至大語言模型

(如 Gemini 2.5 Flash)，並由提示詞約束其輸出，即時將手語倒裝句法轉換為自然流暢的繁體中文語句。

3. 動畫組件

(1) 模型建構與標準化

本系統採用 VRoid 構建標準化的 3D 虛擬人物模型，並匯出為.vrm 格式。該模型具備完整的人體骨骼階層，手部擁有精細的三節指骨設計，能符合手語高複雜度的動作需求。同時具備業界標準的「形態鍵 (Shape Keys / Blendshapes)」，用於生成臉部表情。

(2) 骨骼綁定與動作重定向

本系統利用了阻尼追蹤約束器 (Damped Track Constraint)，將 3D 模型的手指關節指向目標特徵點，並使用父子空間繼承關係



(Parenting) 來做座標空間的校正，確保 MediaPipe 的動作數據能正確映射到 3D 空間的原點模型上，解決網格變形與座標偏移的問題。


(3) 非手控訊號(NMS)之臉部表情連動

三、介面設計說明

本系統 UI 介面說明如下面四張圖：前兩張為電腦版 web 示意圖，後兩張為手機版 web 示意圖，黑色數字框架為功能示意編號，藍色數字框架為大型架構示意編號；編號功能如下表。

數字	黑色	藍色
1	系統介紹	自己的影像 camera 畫面
2	操作說明	AI 的手語翻譯結果畫面
3	對話紀錄	AI 翻譯結果& 非手語使用者輸入內容記錄
4	開始使用 AI	X
5	會員資料	X
6	設定	X
7	登出	X
8	文字輸入框	X
9	開始錄影	X





本系統包含以下主要操作畫面功能：

A. 系統介紹頁

此處介紹系統用途與主要功能。

B. 操作說明頁

此處提供使用者本系統的操作教學。

C. 對話紀錄頁

此處顯示手語者與非手語者歷史對話紀錄。

D. 開始使用 AI (AI 對話頁)

此處提供使用者與 AI 互動

- 使用者輸入訊息 → 顯示於畫面 (於藍色數字 3 處)
- AI 回應(文字) → 顯示回覆內容 (於藍色數字 3 處)
- AI 回應(手語) → 顯示手語內容 (於藍色數字 2 處)

E. 會員資料頁

此處可檢視與修改會員資訊。

F. 設定頁

此處可調整系統使用偏好。

G. 登出功能

此處可讓使用者登出系統。

四、作業程序設計說明

本系統之核心辨識與翻譯生命週期，由主程式 (main.py) 採非同步與多執行緒架構統籌，具體作業程序如下：

1. 初始化與模型掛載 (Initialization)：系統啟動時，並行載入 A 流之 AI 預測模型權重檔，以及 B 流之 database.xlsx 幾何規則庫。同時啟動背景執行緒驗證雲端 LLM 狀態，並初始化 MediaPipe 視覺引擎與攝影機串流。

2. 感知與特徵正規化 (Perception & Normalization)：以 30 FPS

讀取影像串流，進行鏡像翻轉與色彩空間轉換。交由 MediaPipe 提取人體姿態與雙手共 75 個關鍵 3D 拓樸座標點，並完成相對於肩寬的距離正規化 (Normalization)，以適應不同使用者的體型差異。

3. 雙流推論與權重融合 (Hybrid Inference & Weighting)：

a. 並行推論：將正規化後的特徵同步送入雙流。A 流模型計算時序特徵並輸出預測機率分佈；B 流透過邏輯引擎進行幾何閾值匹配。

b. 權重裁決：整合控制中心 (SCI-04) 接收 A、B 雙流的輸出矩陣與布林值，進行加權總和計算。系統會鎖定總積分超過信心閾值 (Confidence Threshold) 的結果，輸出單一確認的手語單字。

4. 非同步翻譯與語意生成 (Asynchronous Translation)：

TranslationWorker 接收融合確認的單字，進行時間戳記比對與防抖過濾。若滿足「手部離開畫面 2 秒」之觸發條件，系統會將收集到的單字佇列發送至 LLM 處理，此非同步設計確保 API 網路請求期間，主影像辨識迴圈依然保持高幀率運行。

5. 視覺化渲染與回饋 (Rendering & UI Output)：將即時辨識狀

態、信心權重等工程數據疊加於原始畫面。當 LLM 翻譯完成時，透過字體渲染引擎將語意重組後的完整中文句子顯示於畫面底部，達成無縫的雙向溝通體驗。

五、輸入/輸出設計說明

1. 輸入資料設計

- 資料來源：來自「影像/翻譯組件」處理後的 MediaPipe 空間座標數據。
- 資料格式：包含多組 3D 空間特徵點座標 (X, Y, Z 軸數值)。核心輸入包含雙手各 21 個手部關節特徵點 (Hand Landmarks)，以及用於判斷表情的臉部關鍵特徵點 (Facial Landmarks)。

2. 輸出資料設計

- 呈現形式：即時運算的 3D 動畫視覺畫面。
- 具體內容：一個能流暢且精準呈現手語動作的 3D 虛擬化身 (Avatar)。該輸出不僅包含正確的手勢與手指彎曲角度，亦同步輸出對應語氣的臉部表情變化，確保聽障使用者能接收到完整且正確的視覺化手語翻譯資訊。

六、其他設計說明

1. 系統例外處理與容錯設計 (Exception Handling)

關鍵點缺失處理： 若影像組件偵測到「肩膀」或「手腕」等核心基準點消失 (如使用者移出畫面)，系統將暫停辨識並在 UI 顯示「請將全身/雙手置於鏡頭內」之提示。

低置信度過濾： 當 A 流模型輸出的機率值低於 0.6 時，系統將判定為「無效動作」，不進行文字呈現，以避免出現錯誤翻譯干擾使用者。

2. 環境適應性設計

動態原點調整： 系統每幀重新計算「鼻子」作為參考原點，因此使用者在辨識過程中發生小範圍位移或站位偏斜時，系統仍能維持特徵向量的一致性。

光線適應性： 由於特徵提取 (MediaPipe) 主要依賴輪廓與關鍵點，系統在不同色溫環境下仍具備良好的辨識穩定性。

肆、需求追溯與版本管理

版本號	修訂日期	修改內容摘要
1.0	2025/10/13	建立第一次系統基礎架構
1.1	2025/12/24	增加多層頁面
1.2	2026/2/9	新增語音、攝影機
2.0	2026/4/11	大修改整體系統框架

附錄 訊息清單

檔案與程式對照表

檔案與報表對照表